EFC 2

Cláudio Ferreira Carneiro - RA 263796

October 17, 2019

1 Parte 1 –Classificação binária

O código referente às atividades se encontra no repositório:
https://github.com/carneirofc/IA006.git

1.1 a) Características dos atributos de entrada

Os histogramas dos atributos em sua forma original são apresentados nas figuras [1], [2] e [3]. A correlação dos atributos é apresentada na forma de um *heatmap* [4] e por gráficos de dispersão [5] (na diagonal principal é exibido o histograma do atributo). Percebe-se que determinados atributos apresentam alto grau de correlação.

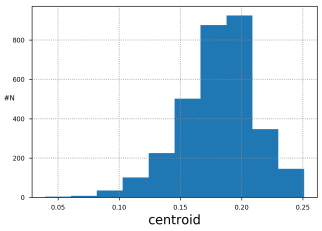

(a) Centroid

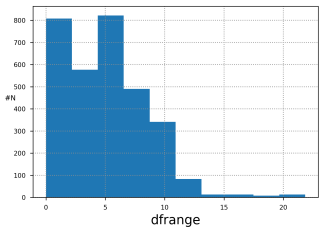

(b) F-Range

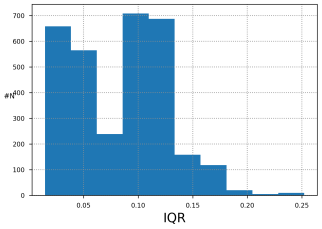

(c) IQR

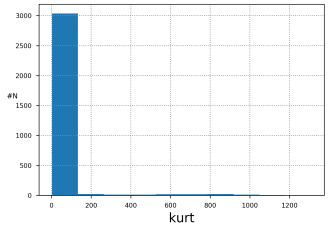

(d) Kurt

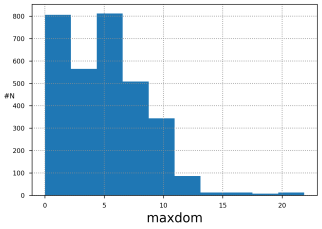

(e) Max dom

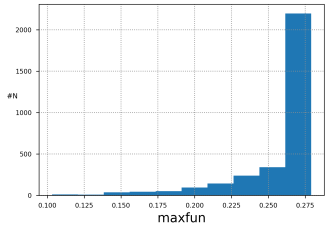

(f) Max fun

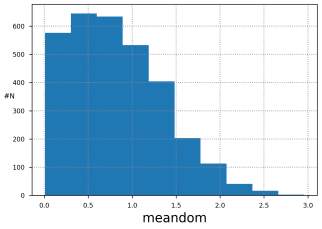

(g) Mean dom

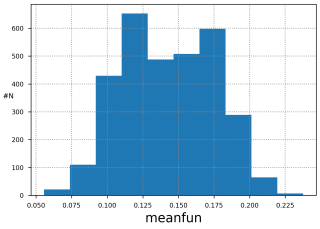

(h) Mean fun

Figure 1: Classificação binária: Histograma dos atributos (1)

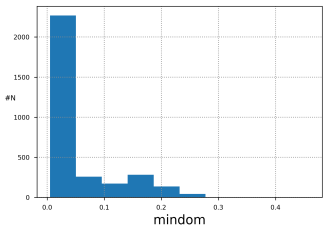

(a) Min dom

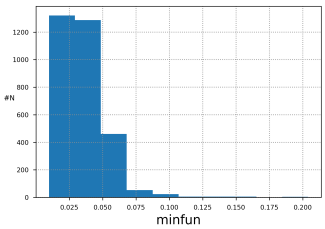

(b) Min fun

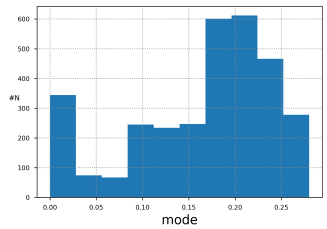

(c) Mode

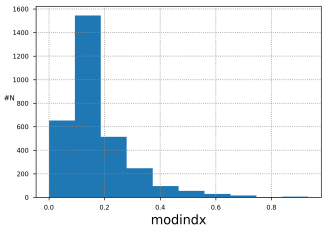

(d) modindx

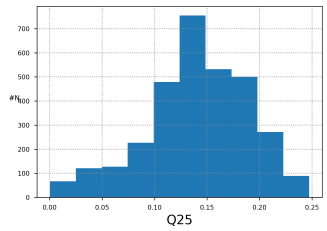

(e) Q25

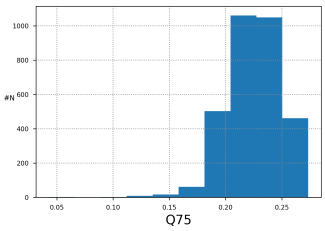

(f) Q75

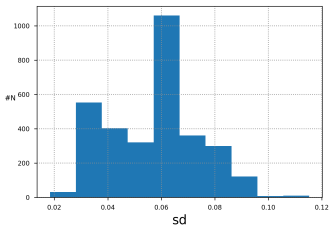

(g) sd

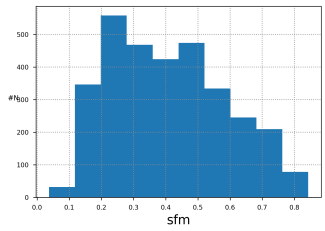

(h) sfm

Figure 2: Classificação binária: Histograma dos atributos (2)

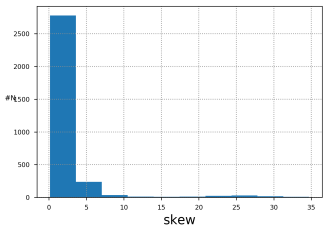

(a) skew

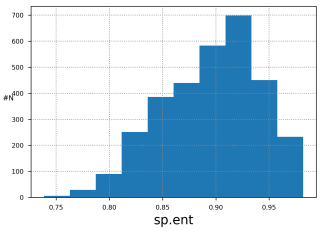

(b) histsp.ent

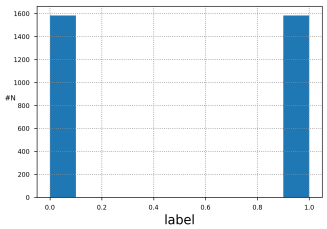

(c) label

Figure 3: Classificação binária: Histograma dos atributos (3)

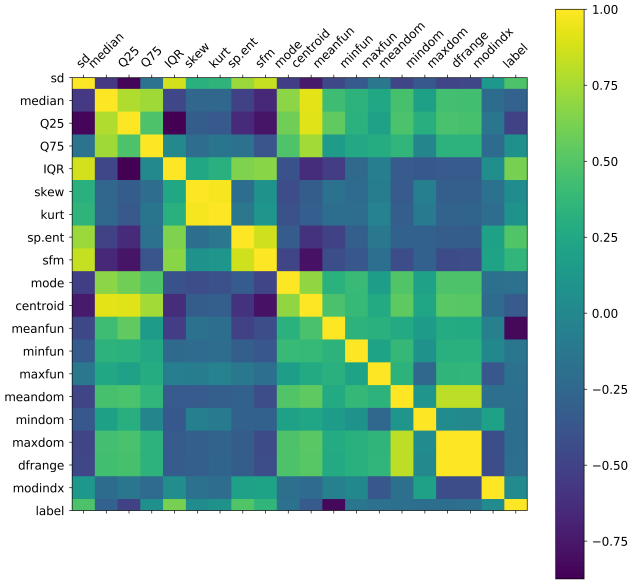

Figure 4: Classificação binária: Mapa de calor da correlaçao dos atributos

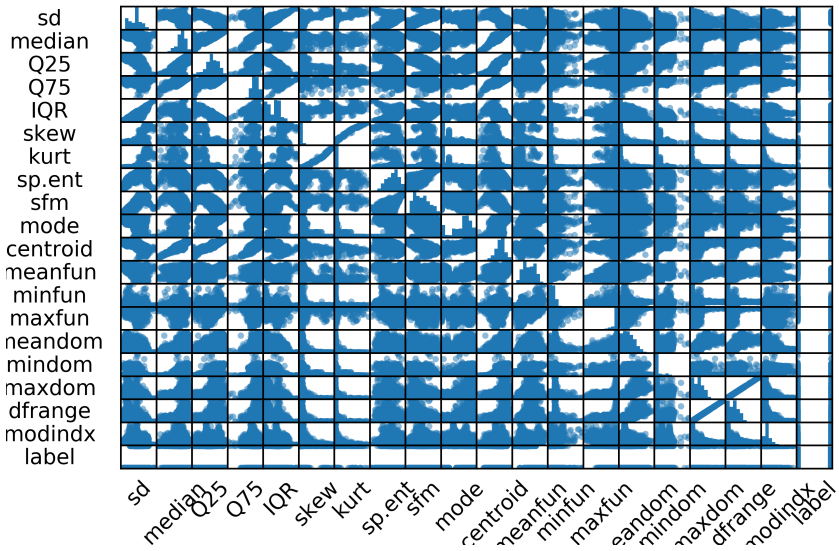

Figure 5: Classificação binária: Correlação dos atributos em gráfico de dispersão

1.2 b) Curva ROC e F_1-medida

É utilizado o método *Z-score* para normalização dos dados. Tal método foi escolhido pois favorece o progresso de algoritmos baseados no gradiente descendente, uma vez que deixa as curvas de nível da superfície de erro mais circulares.

O processo de treinamento tem como critério de parada a variação da função de custo. Quando o decréscimo por década do custo for inferior a 10^{-8} é terminado o processo de treinamento.

Parâmetros de treinamento:

$$\eta = 10^{-2}$$
$$tol = 10^{-8}$$

sendo η a taxa de aprendizagem e tol o limiar para o término do treinamento.

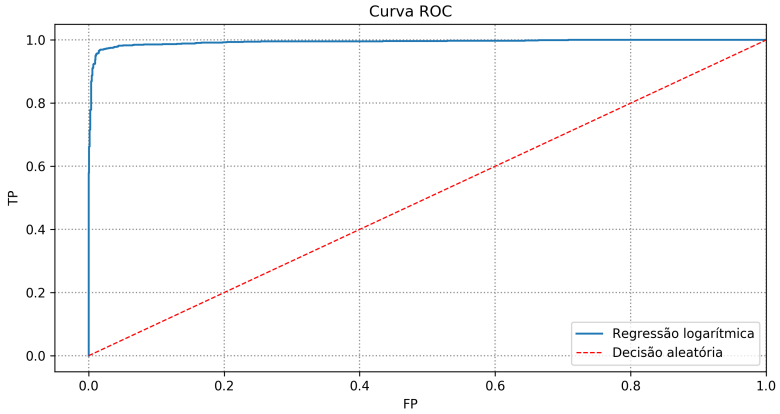

Figure 6: Classificação binária: Curva ROC relativa aos dados de Teste

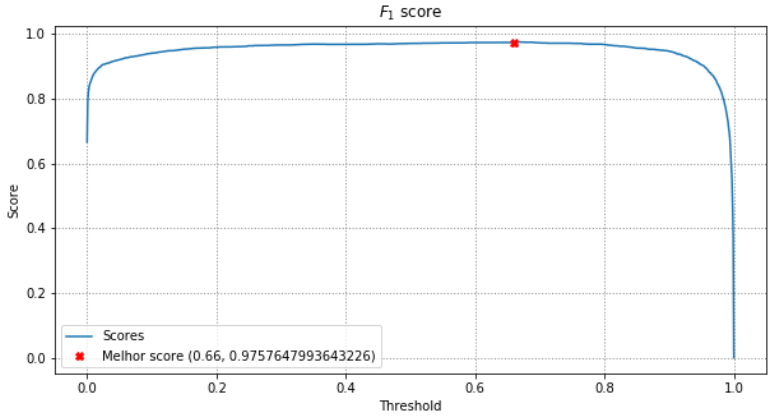

Figure 7: Classificação binária: F_1-medida relativa aos dados de Teste

1.3 c) Melhor *threshold*, matriz de confusão e acurácia

Para a escolha do valor de *threshold* será utilizada a F_1-medida, de forma que o *recall* e precisão do classificador tenham a mesma importância.

Conforme apresentado na figura [7], o ponto de máxima F_1-medida é obtido com:

$$threshold = 0.663$$
$$F_1 - medida \approx 0.9757$$

Utilizando o limiar de máxima F_1-medida, a classificação do *dataset* de testes é apresentada conforme a matriz de confusão:

			Classe Estimada	
			Feminino	Masculino
			+	-
Classe	Feminino	+	1227	40
Verdadeira	Masculino	-	21	1246

O classificador apresenta acurácia (acc), precisão (prec) e *recall* de:

$$acc \approx 0.9759$$
$$prec \approx 0.9832$$
$$recall \approx 0.9684$$